Lezione 05: Ristrutturazione diagrammi

BASI DI DATI I



DIETI UNIVERSITA' DEGLI STUDI DI NAPOLI FEDERICO II

DIPARTIMENTO DI INGEGNERIA ELETTRICA E DELLE TECNOLOGIE DELL'INFORMAZIONE

A.A. 2022/2023

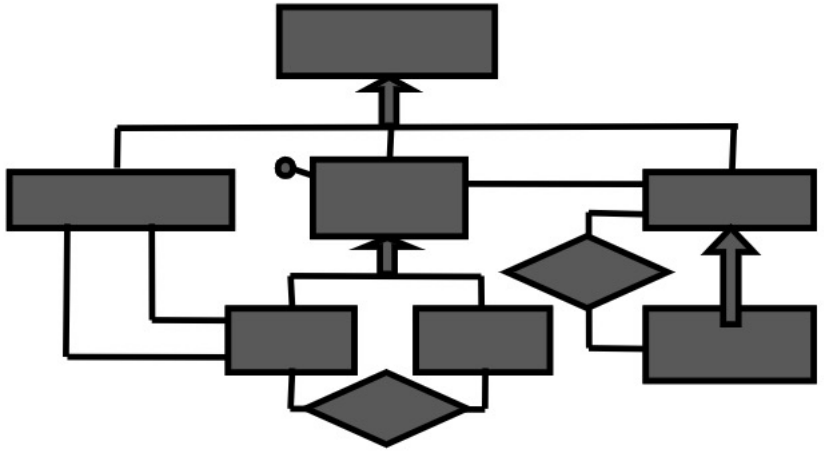
Prof. Silvio Barra

RISTRUTTURAZIONE DEL MODELLO CONCETTUALE

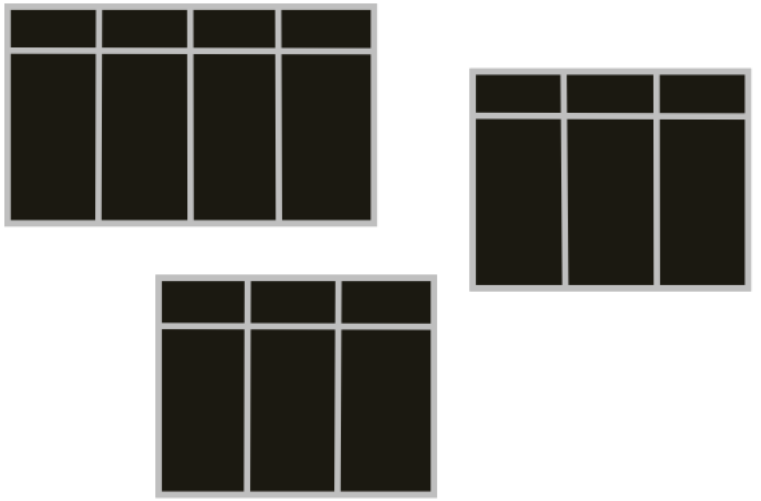


PASSAGGIO DAL MODELLO CONCETTUALE A QUELLO LOGICO

Abbiamo visto come costruire un modello concettuale del nostro minimondo



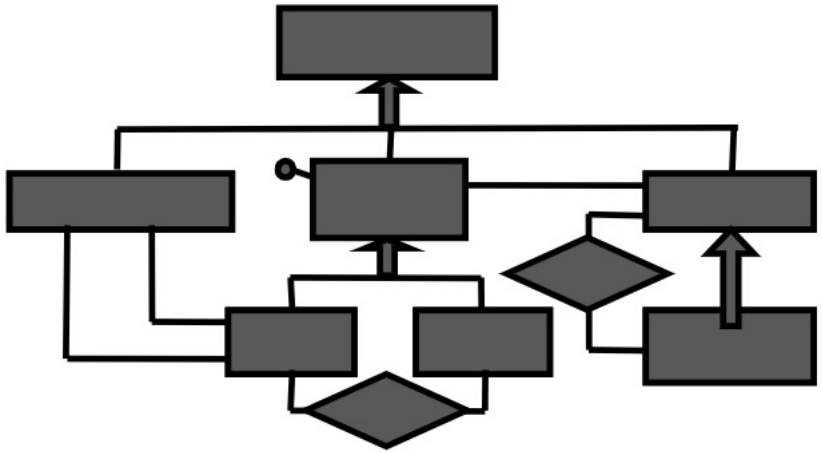
Abbiamo visto in cosa consiste il modello logico, che è la successiva fase di progettazione



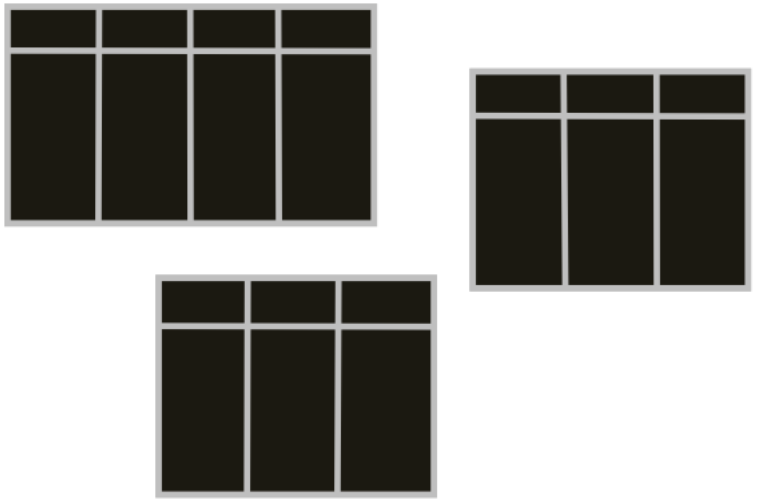
PASSAGGIO DAL MODELLO CONCETTUALE A QUELLO LOGICO

Abbiamo visto come costruire un modello concettuale del nostro minimondo

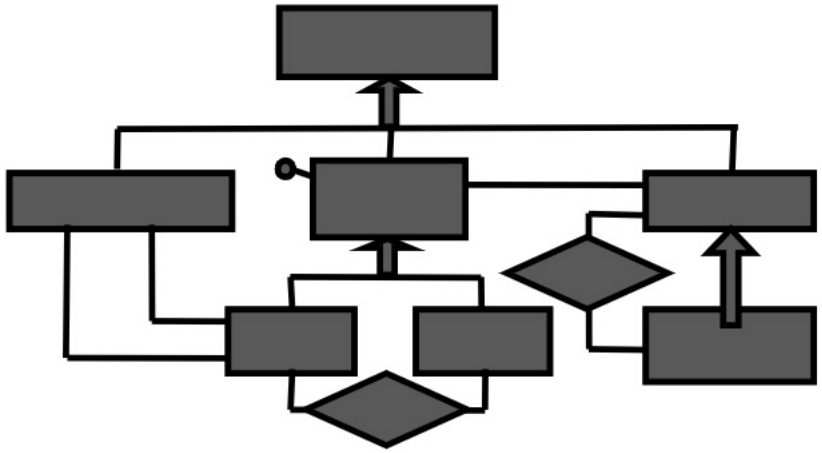
Abbiamo visto in cosa consiste il modello logico, che è la successiva fase di progettazione



Processo di traduzione

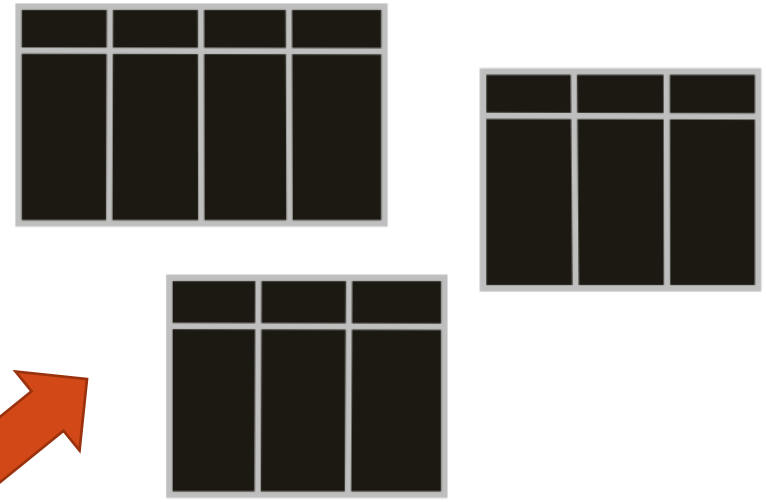


STEP INTERMEDI



Ottimizzazione
del diagramma

Applicazione regole
di traduzione



RISTRUTTURAZIONE

- Prima di passare allo schema logico è necessario ristrutturare il Class Diagram (o l'ER diagram) per:
  - Semplificare la traduzione:

    non tutti i costrutti che abbiamo utilizzato hanno una traduzione naturale nei modelli logici.
  - Ottimizzare il progetto:

    rendere più efficiente l'esecuzione delle operazioni.

L'obiettivo è creare uno schema logico in grado di descrivere tutte le informazioni contenute negli schema concettuali prodotti nella fase di progettazione concettuale.



ATTIVITÀ DI RIORGANIZZAZIONE E TRADUZIONE

- La fase di ristrutturazione *si basa su criteri di ottimizzazione dello schema*.

- Traduzione verso il modello logico:
  - *fa riferimento ad uno specifico modello logico*.

- I dati in ingresso sono lo schema concettuale ed il carico applicativo (dimensione dei dati e caratteristiche delle operazioni).

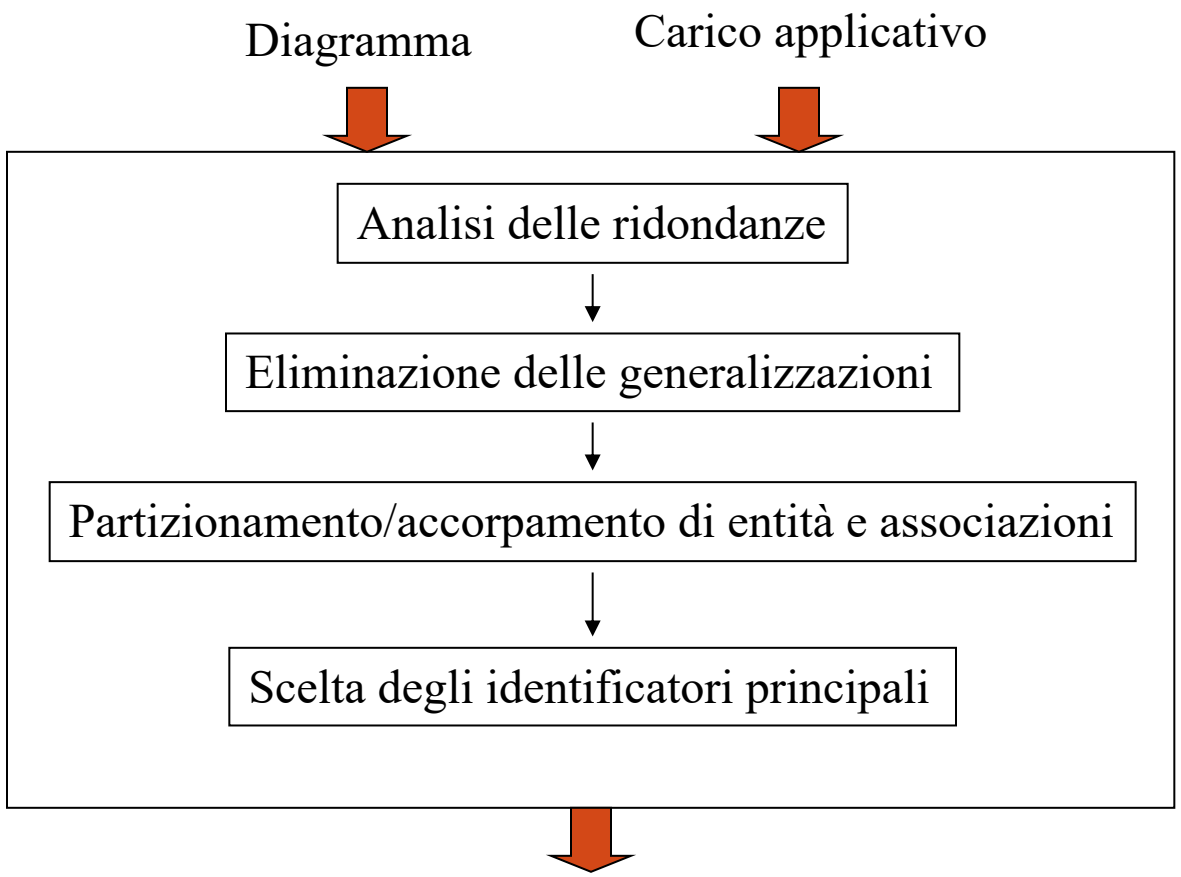


PREAMBOLO

- Le regole di ristrutturazione si applicano sia ai Class Diagram che ai diagrammi ER
- Questo perché
  - Ogni concetto che estende la rappresentazione concettuale del miniworld ha sia un formalismo in ER/EER sia può essere rappresentato tramite una notazione UML
  - L'obiettivo finale è quello di tradurre il modello concettuale nel modello logico, che è unico. Il punto di arrivo è lo stesso



RISTRUTTURAZIONE DI SCHEMI CONCETTUALI



PREAMBOLO

- Le regole di ristrutturazione si applicano sia ai Class Diagram che ai diagrammi ER
- Questo perché
  - Ogni concetto che estende la rappresentazione concettuale del miniworld ha sia un formalismo in ER/EER sia può essere rappresentato tramite una notazione UML
  - L'obiettivo finale è quello di tradurre il modello concettuale nel modello logico, che è unico. Il punto di arrivo è lo stesso

- *Per semplicità, per mostrare le regole di ristrutturazione, utilizzeremo la notazione UML, ma è chiaro che la stessa regola può essere applicata analogamente ai diagrammi ER.*



TAVOLE DI ANALISI



ANALISI DELLE PRESTAZIONI

- Indici di prestazioni (non valutabili in maniera precisa in sede di progettazione logica):
  - Costo di una operazione (# occorrenze di entità e relazioni visitate per rispondere a una operazione).
  - Occupazione di memoria.

Per studiare questi parametri è necessario conoscere:

- Volume dei dati:
  - # occorrenze di entità e relazioni.
  - Dimensioni di ciascun attributo.
- Caratteristiche delle operazioni:
  - Tipo (interattiva o batch).
  - Frequenza (# medio di esecuzioni in un *t*).
  - Dati coinvolti.



TAVOLE DI ANALISI

- Tavola dei volumi:

  concetto tipo volume

  - Vengono riportati tutti i concetti dello schema (entità e relazioni) con il volume previsto a regime.

- Tavola delle operazioni:

  operazioni tipo frequenza

  - Viene riportata per ogni operazione la frequenza prevista, il tipo (interattiva o batch).

- Tavola degli accessi

  concetto costrutto accessi tipo

  - Viene riportata, per ogni operazione, il numero di accessi ai concetti coinvolti ed il tipo di accesso (L/S).
  - Le operazioni in scrittura (S) sono più onerose di quelle in lettura (L).



ESEMPIO

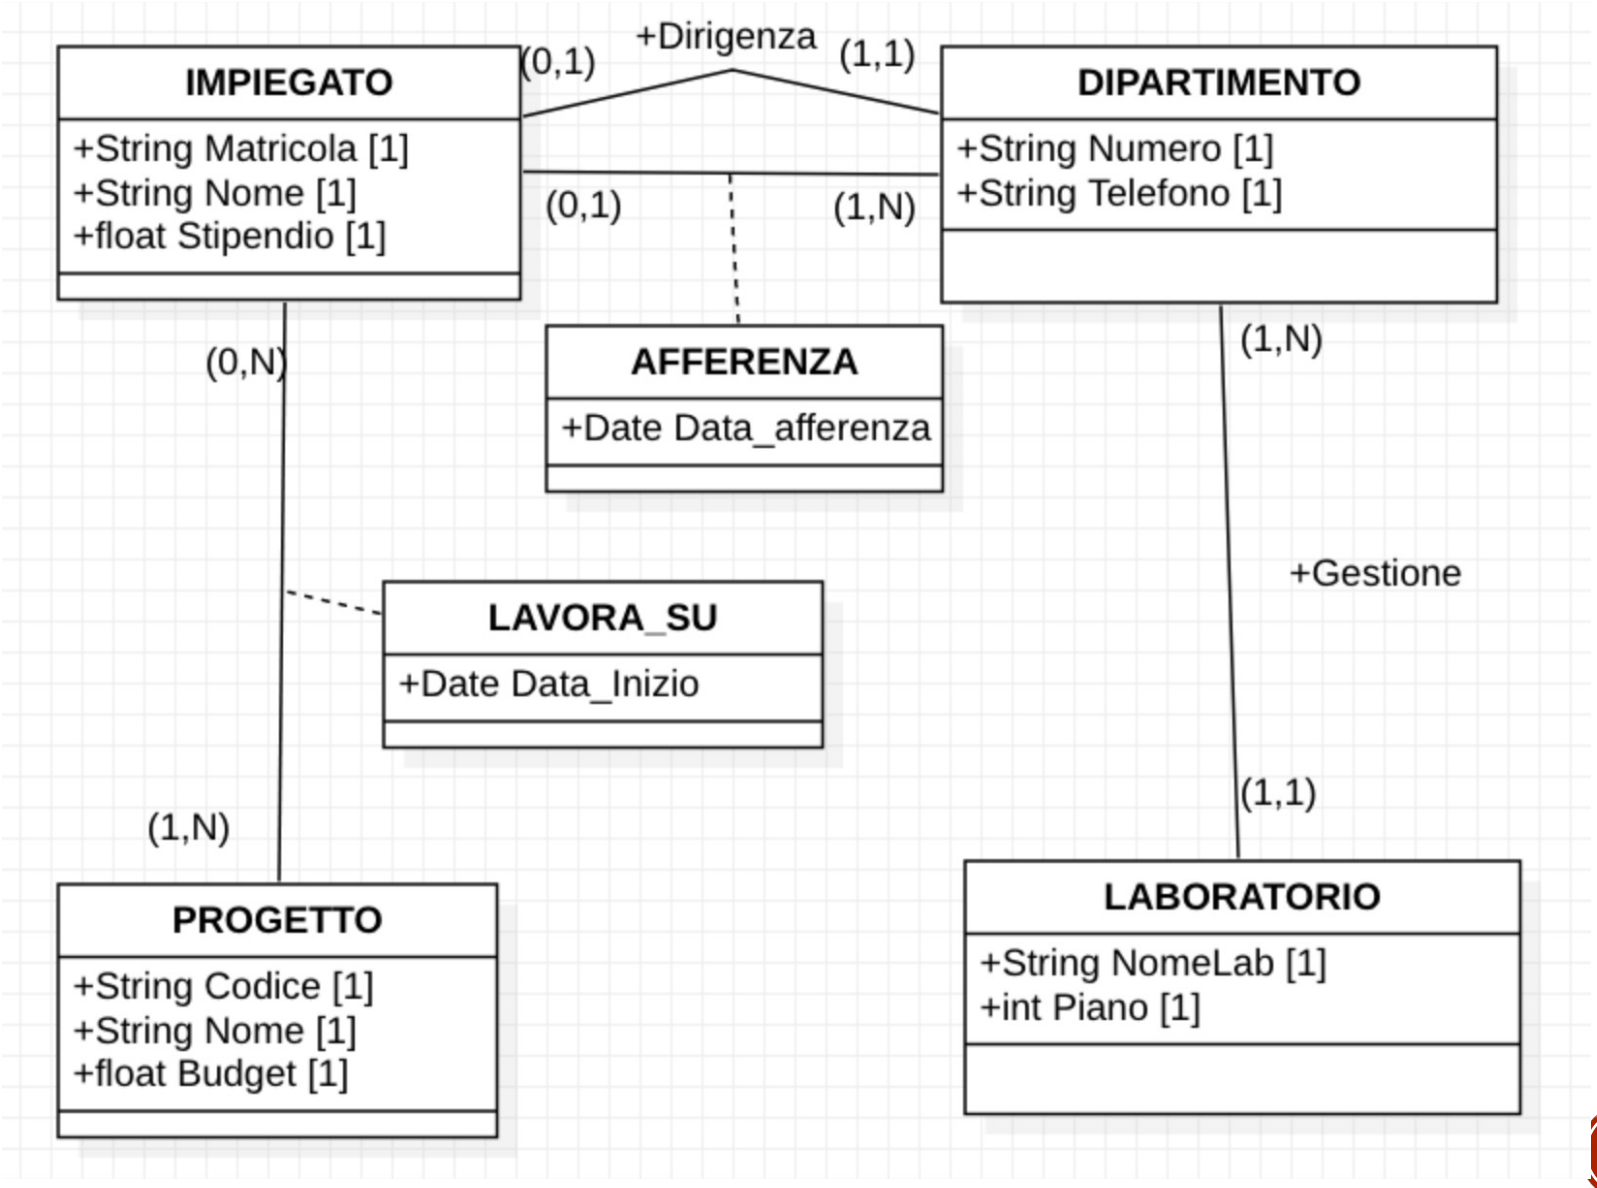

IMPIEGATO
+String Matricola [1]
+String Nome [1]
+float Stipendio [1]
(0,1)
+Dirigenza
(1,1)
DIPARTIMENTO
+String Numero [1]
+String Telefono [1]
(0,1)
(1,N)
AFFERENZA
+Date Data_afferenza
(0,N)
(1,N)
+Gestione
LAVORA_SU
+Date Data_Inizio
(1,N)
(1,1)
PROGETTO
+String Codice [1]
+String Nome [1]
+float Budget [1]
LABORATORIO
+String NomeLab [1]
+int Piano [1]

TAVOLA DEI VOLUMI

Concetto	Tipo	Volume
Laboratorio	E	100
Dipartimento	E	80
Impiegato	E	2000
Progetto	E	500
Gestione	R	100
Afferenza	R	1900
Dirigenza	R	80
Lavora_Su	R	6000



NUMERO DELLE OCCORRENZE DELLE ASSOCIAZIONI

- L'analisi della tavola dei volumi dipende da due parametri:
  - Numero delle occorrenze delle entità coinvolte nelle relazioni.
  - Numero medio di partecipazioni di un'occorrenza di entità alle occorrenze di relazioni.

Es: supponiamo che un impiegato lavori in media a tre progetti.

TAVOLA DELLE OPERAZIONI

- Per l'analisi delle operazioni vado a valutare
  1. Quali sono le operazioni che vengono fatte sulla base di dati
  2. Sulla base di quelle che sono le operazioni più frequenti, vado a vedere il costo per effettuarla



OPERAZIONI

1. Assegna un impiegato ad un progetto.
2. Trova i dati di un impiegato, del dipartimento nel quale lavora e dei progetti ai quali partecipa.
3. Trova i dati di tutti gli impiegati di un certo dipartimento.
4. Per ogni sede, trova i suoi dipartimenti con il cognome del direttore e l'elenco degli impiegati del dipartimento.



TAVOLA DELLE OPERAZIONI

Operazione	Tipo	Frequenza
Op. 1	I	50 al giorno
Op. 2	I	100 al giorno
Op. 3	I	10 al giorno
Op. 4	B	2 a settimana

I: interattiva. Sono gli utenti della base di dati che effettuano queste operazioni
B: batch. Operazioni pianificate in un determinato arco di tempo

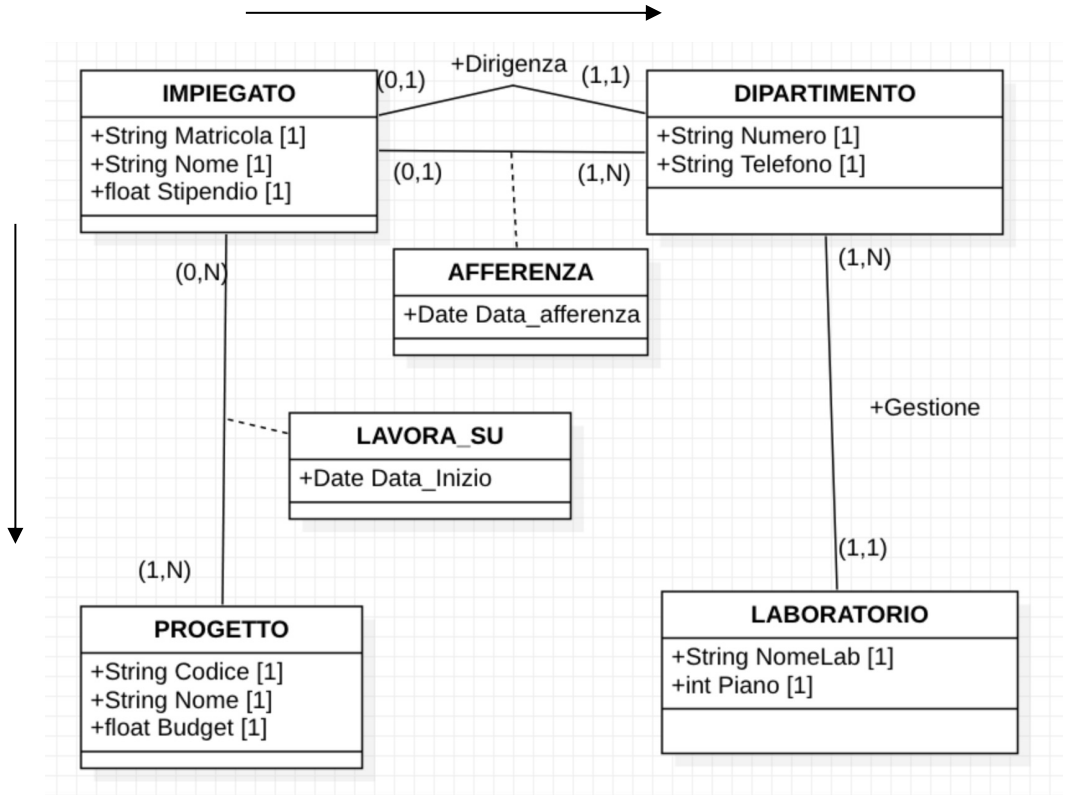


SCHEMA DI OPERAZIONE

- Per ogni operazione possiamo descrivere graficamente i dati coinvolti attraverso uno **schema di operazione**.
- Descrive il cammino logico da percorrere per accedere alle informazioni di interesse.

Operazione 2

Trova i dati di un impiegato, del dipartimento nel quale lavora e dei progetti ai quali partecipa.



COSTO DI UN'OPERAZIONE

- Si stima il costo di un'operazione contando il numero degli accessi alle occorrenze di entità e di relazioni.
- Ipotizziamo che il costo di una lettura è *x*, mentre il costo di una scrittura è *y*.



TAVOLA DEGLI ACCESSI (RIF. OP. 2)

Concetto	Costrutto	Accessi	Tipo
Impiegato	E	1	L
Afferisce	R	1	L
Dipartimento	E	1	L
Partecipa	R	3	L
Progetto	E	3	L



PASSAGGI NELLA RISTRUTTURAZIONE



RISTRUTTURAZIONE DEL CLASS DIAGRAM

- La fase di ristrutturazione di uno schema concettuale è suddiviso:
  1. Analisi delle ridondanze.
  2. Eliminazione delle generalizzazioni.
  3. Eliminazione Attributi Multivalore
  4. Eliminazione Attributi Strutturati
  5. Partizionamento/accorpamento di entità e associazioni.
  6. Scelta degli identificatori primari.



ANALISI DELLE RIDONDANZE



ANALISI DELLE RIDONDANZE

- Una **ridondanza** in uno schema concettuale corrisponde alla presenza di un dato che può essere derivato da altri dati.

- Vantaggi
  - Semplificazione delle interrogazioni.

- Svantaggi
  - Appesantimento degli aggiornamenti.
  - Maggiore occupazione di spazio.

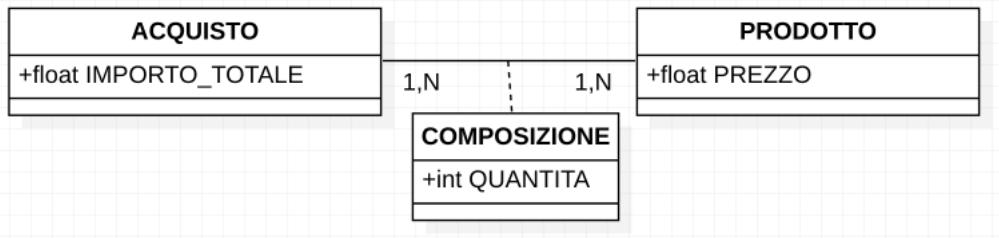


ATTRIBUTI DERIVABILI

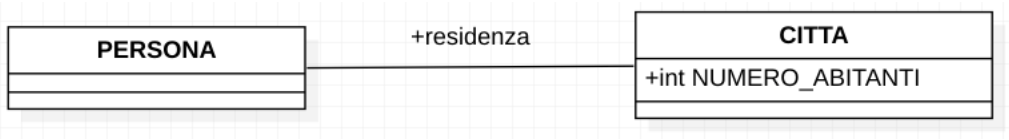
- Da attributi della stessa entità /associazione:



- Da attributi di altre entità/associazioni

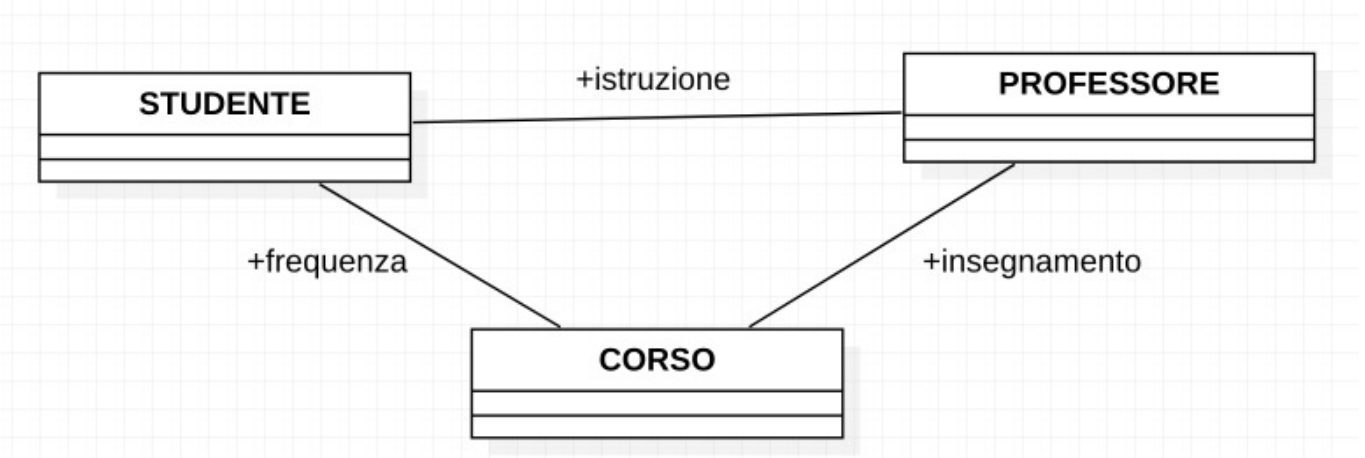


- Dal conteggio di occorrenze



ATTRIBUTI DERIVABILI (4)

- Da associazioni in presenza di cicli:



- La presenza di cicli non genera necessariamente ridondanze:
  - ***Si immagini che l'associazione "istruzione"*** fosse ***"è tesista di"***.

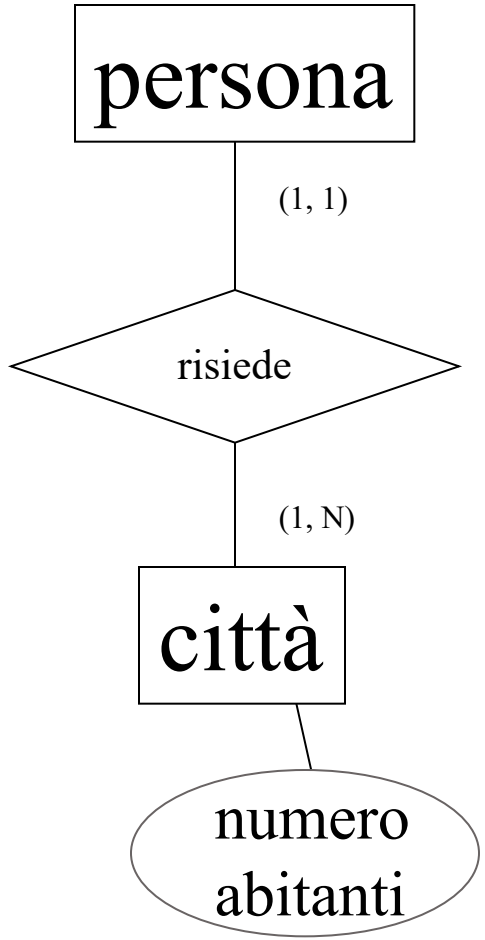
INSERIRE UNA RIDONDANZA?

- La decisione va presa confrontando il costo delle operazioni che coinvolgono il dato ridondante e relativa occupazione di memoria nei casi di **presenza/assenza** di ridondanza.



TAVOLE DI ANALISI

- Tavola dei volumi:
  - Città E 200
  - Persona E 1000000
  - Risiede R 1000000



- Op_1: *memorizza una nuova persona con la relativa città di residenza*.
- Op_2: *stampa tutti i dati di una città (incluso il numero di abitanti)*.

- Tavola delle operazioni:
  - Op_1 I 500/giorno
  - Op_2 I 2/giorno

"NUMERO DI ABITANTI" → CITTÀ

- Proviamo a valutare gli indici di prestazione in caso di presenza del dato ridondante:

- Mem(num_abit) $\cong$ 4 byte $\rightarrow$ dato ridondante $\cong 4 \times 200 = 800$ byte ($\cong$ 1 kbyte)

- Costo:*Un accesso in scrittura ha un costo doppio rispetto ad un accesso in lettura*

TAVOLE DEGLI ACCESSI (CON RIDONDANZA)

- Operazione 1: *memorizza una nuova persona con la relativa città di residenza*.
  - Persona E 1 S

    (per memorizzare una nuova persona)
  - Risiede R 1 S

    (per memorizzare una nuova coppia città-persona)
  - Città E 1 L

    (per cercare la città di interesse)
  - Città E 1 S

    (incrementa di 1 il numero di abitanti)

- 3S * 500/giorno + 1L * 500/giorno

  ⇓

- 3500 accessi/giorno

(un accesso in scrittura vale il doppio di un accesso in lettura)

- Operazione 2: *stampa tutti i dati di una città (incluso il numero di abitanti)*.
  - Città E 1 L

- Trascurabile: 1L * 2/giorno

TAVOLE DEGLI ACCESSI (SENZA RIDONDANZA)

- Op.1: *memorizza una nuova persona con la relativa città di residenza*.
  - Persona E 1 S
  - Risiede R 1 S

  (non si accede a Città per aggiornare il dato derivato)
  - 2S * 500/giorno

    ⇓
  - 2000 accessi/giorno

    (contano doppio gli accessi in scrittura)

- Op.2: *stampa tutti i dati di una città (incluso il numero di abitanti)*.
  - Città E 1 L
  - Risiede R 5000[1] L

  - 1L + 1L * 5000 * 2/giorno

    ⇓
  - 10000 accessi/giorno

[1] (#abitanti/città=1000000/200)

- **12.000 accessi *vs* 3.500 accessi + 1Kbyte**
- Gli accessi in lettura necessari per calcolare il dato derivato sono molti di più degli accessi in scrittura per mantenerlo aggiornato.

ELIMINAZIONE DELLE GENERALIZZAZIONI



ELIMINAZIONE DELLE GENERALIZZAZIONI

- I sistemi tradizionali per la gestione di basi di dati non consentono di rappresentare direttamente una generalizzazione.

- È necessario tradurre le generalizzazioni usando altri costrutti della modellazione concettuale (classi/entità, associazioni/relazioni)



ELIMINAZIONE DELLE GENERALIZZAZIONI

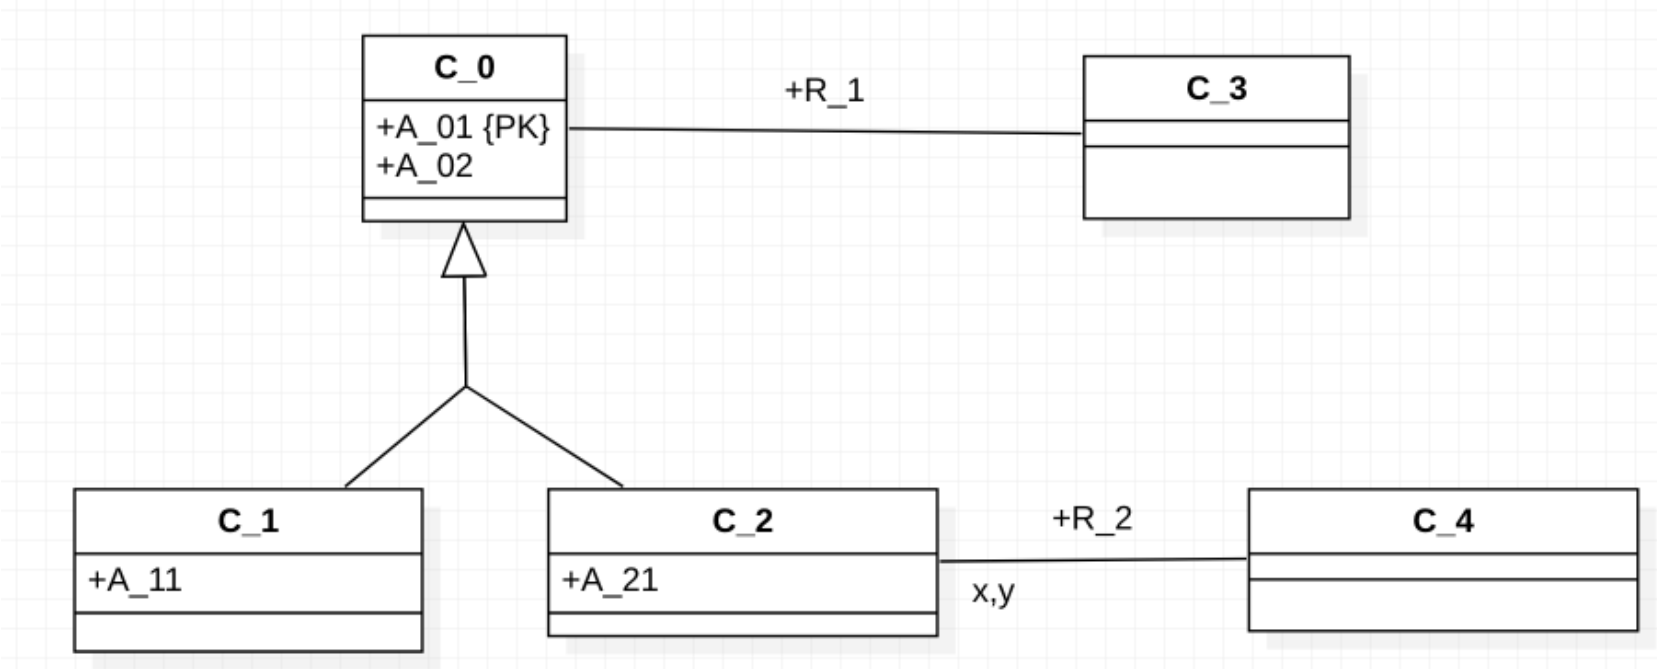
a) Accorpamento delle figlie della generalizzazione nel padre.

b) Accorpamento del padre della generalizzazione nelle figlie.

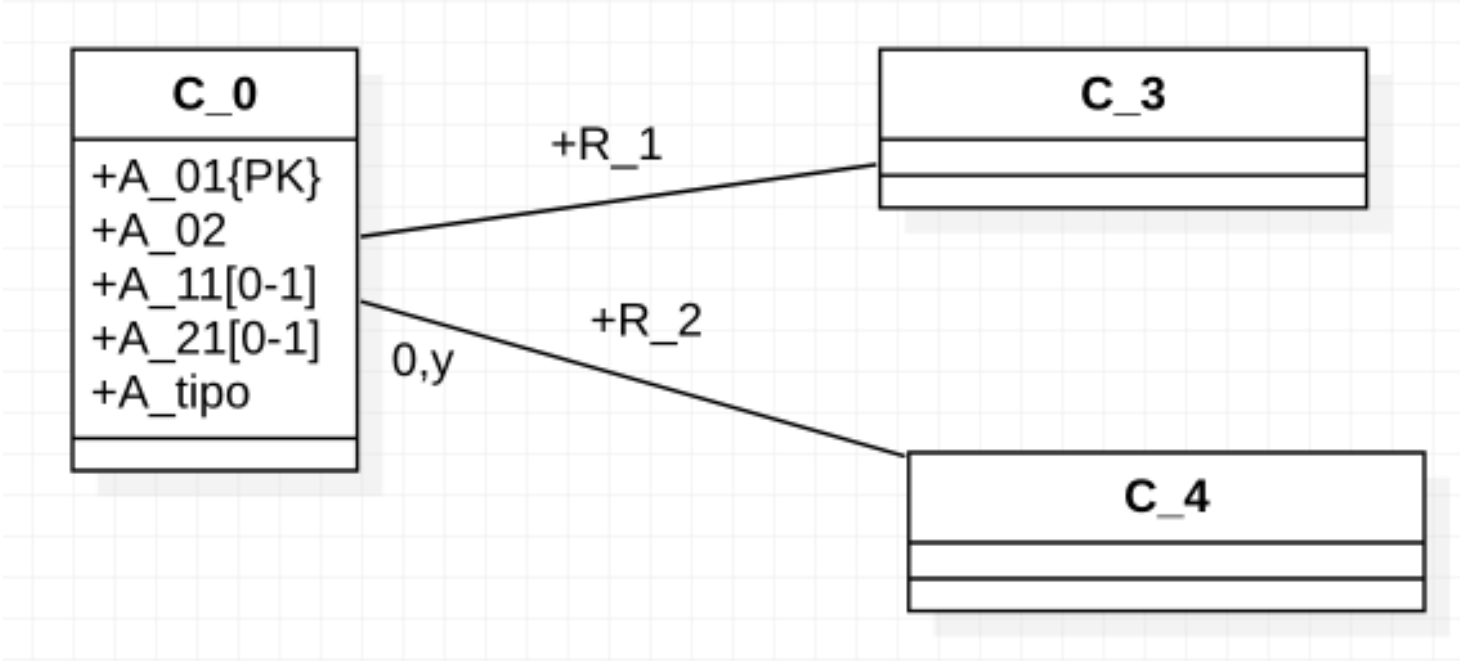
c) Sostituzione della generalizzazione con associazioni.



SCHEMA INIZIALE

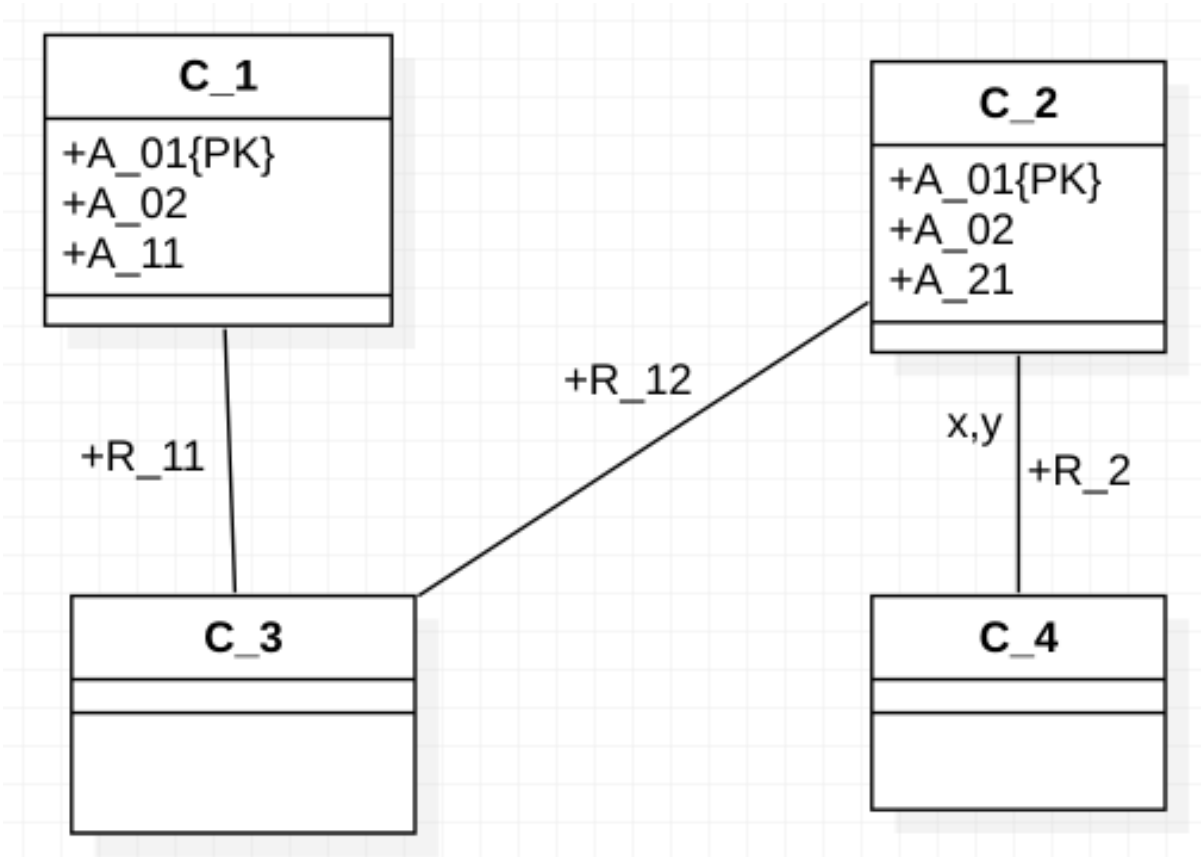


(A) ACCORPAMENTO DELLE FIGLIE DELLA GENERALIZZAZIONE NEL PADRE



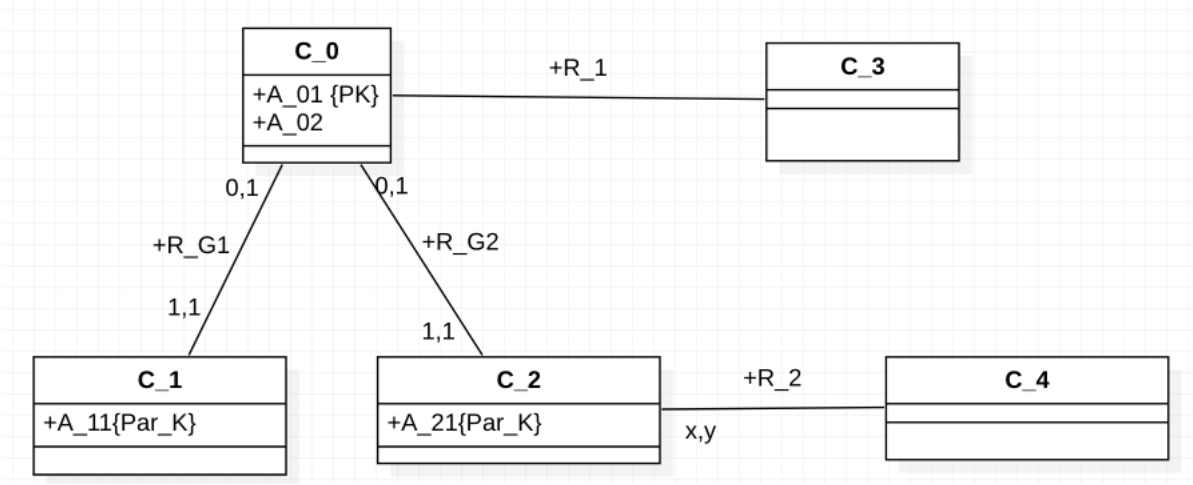
Le entità C_1 e C_2 vengono eliminate e le loro proprietà vengono aggiunte al padre C_0.

(B) ACCORPAMENTO DEL PADRE DELLA GENERALIZZAZIONE NELLE FIGLIE



(C) SOSTITUZIONE DELLA GENERALIZZAZIONE CON ASSOCIAZIONI

- Le entità C_1 e C_2 sono identificate esternamente dall'entità C_0:
- **Vincoli:** ogni occorrenza di C_0 non può partecipare contemporaneamente a R_{G1} ed R_{G2} se la generalizzazione è totale, ogni occorrenza di E_0 deve partecipare o ad un'occorrenza di R_{G1} o ad un'occorrenza di R_{G2}



- Vincolo di totalità: Un elemento di C_0 è associato ad un elemento di C_1 o di C_2
  - (Parziale se un elemento di C_0 non è associato a nessuno dei figli)
- Vincolo di disgiunzione: Un elemento di C_0 non può essere associato a entrambi i figli
  - (Overlapping se un elemento può essere associato a entrambi i figli)

COME SCEGLIERE TRA LE DIVERSE ALTERNATIVE

- L'alternativa **(a)** conviene quando le operazioni non fanno molta distinzione tra le occorrenze e tra gli attributi di C_0, C_1, ed C_2. Introduciamo valori nulli, ma abbiamo un minor numero di accessi.

- L'alternativa **(b)** è applicabile quando la generalizzazione è totale. Altrimenti le occorrenze di C_0 che non sono occorrenze né di C_1, né di C_2 non sarebbero rappresentate.

- L'alternativa **(c)** è applicabile quando la generalizzazione non è totale, e ci sono operazioni che fanno distinzione tra entità padre ed entità figlie. Assenza di valori nulli e incremento degli accessi.



COME SCEGLIERE TRA LE DIVERSE ALTERNATIVE (2)

- La ristrutturazione delle generalizzazioni è un tipico caso per cui il conteggio delle istanze e degli accessi non permette sempre di scegliere la migliore alternativa.
- Infatti, sembrerebbe che l'alternativa **(c)** non conviene quasi mai perché richiede molti più accessi per eseguire le operazioni sui dati.
- Questo tipo di ristrutturazione ha il grosso vantaggio di generare entità con pochi attributi:
  - A livello pratico questo si traduce in strutture logiche di piccole dimensioni per cui un accesso fisico permette di recuperare molti dati (tuple) in una sola volta.



GENERALIZZAZIONI A PIÙ LIVELLI

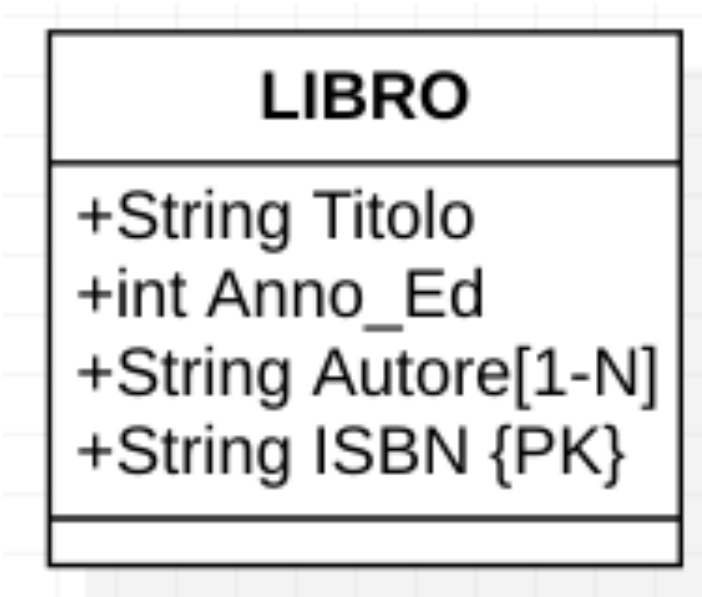
- Per le generalizzazioni a più livelli si può procedere analizzando una generalizzazione alla volta a partire dal fondo della gerarchia.

ELIMINAZIONE ATTRIBUTI MULTIVALORE

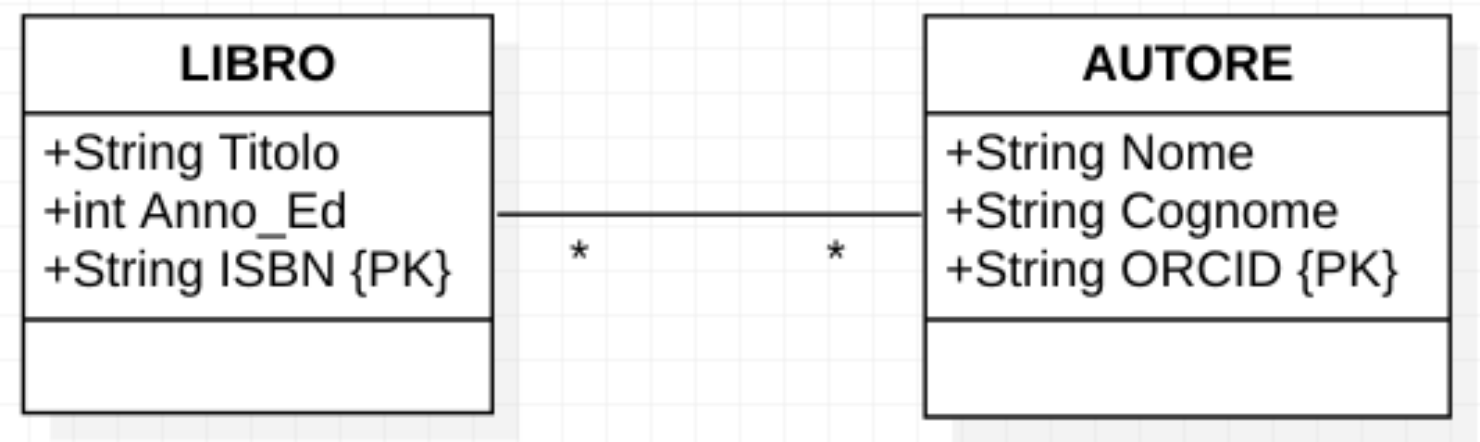


ELIMINAZIONE ATTRIBUTI MULTIVALORE

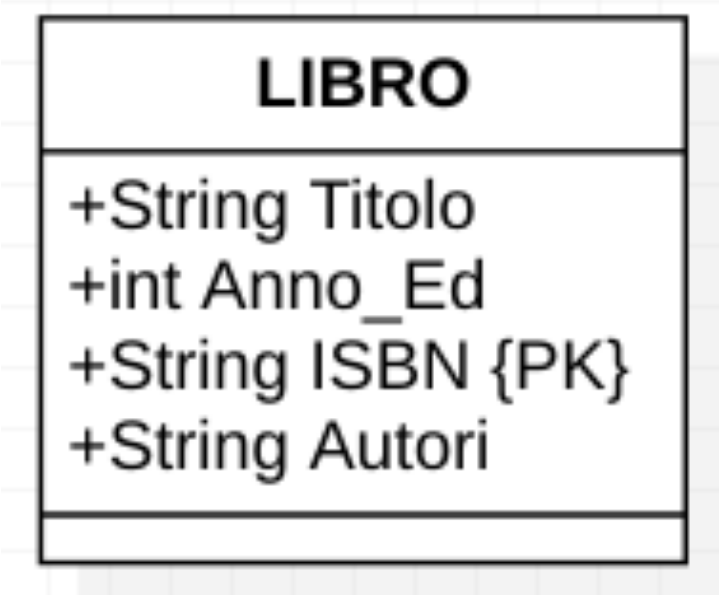
- Il modello relazionale non consente questa rappresentazione:



1) CREAZIONE DI UNA ENTITÀ ESTERNA ASSOCIATA



2) TRATTARE L'ATTRIBUTO MULTIPLO COME FOSSE SINGOLO



Titolo: «Sistemi di basi di dati»
Anno_Ed: «2015»
ISBN: «6767-8754»
Autori: «Elmasri, Navathe»

3) REPLICARE L'ATTRIBUTO NELLA CLASSE (QUANTE VOLTE??)

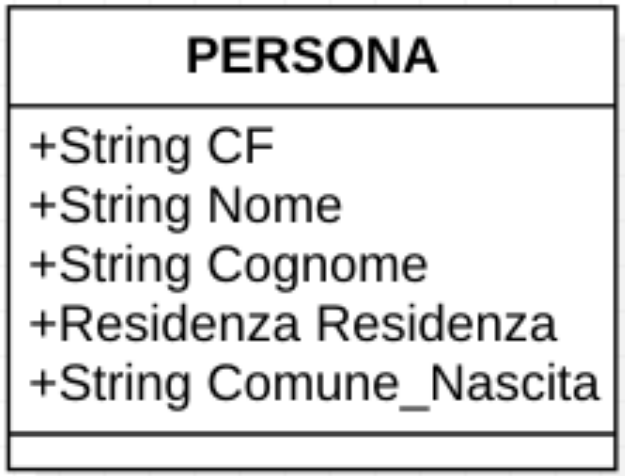


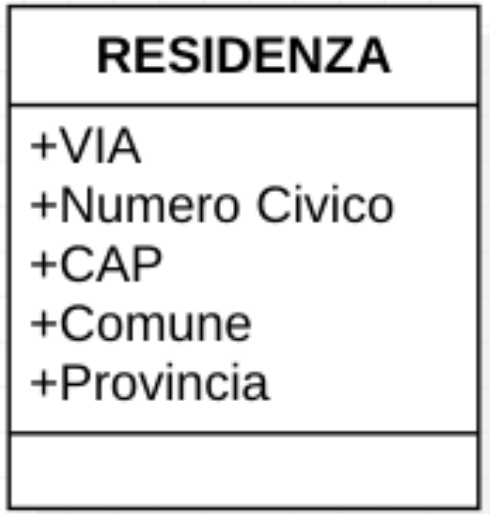
- Per alcuni casi potrebbe anche andare bene.
- Persona-> Telefono1, Telefono2
- Per un numero limitato di volte potrebbe essere una soluzione accettabile
  - Andare troppo oltre potrebbe causare un numero eccessivo di campi vuoti

ELIMINAZIONE ATTRIBUTI STRUTTURATI

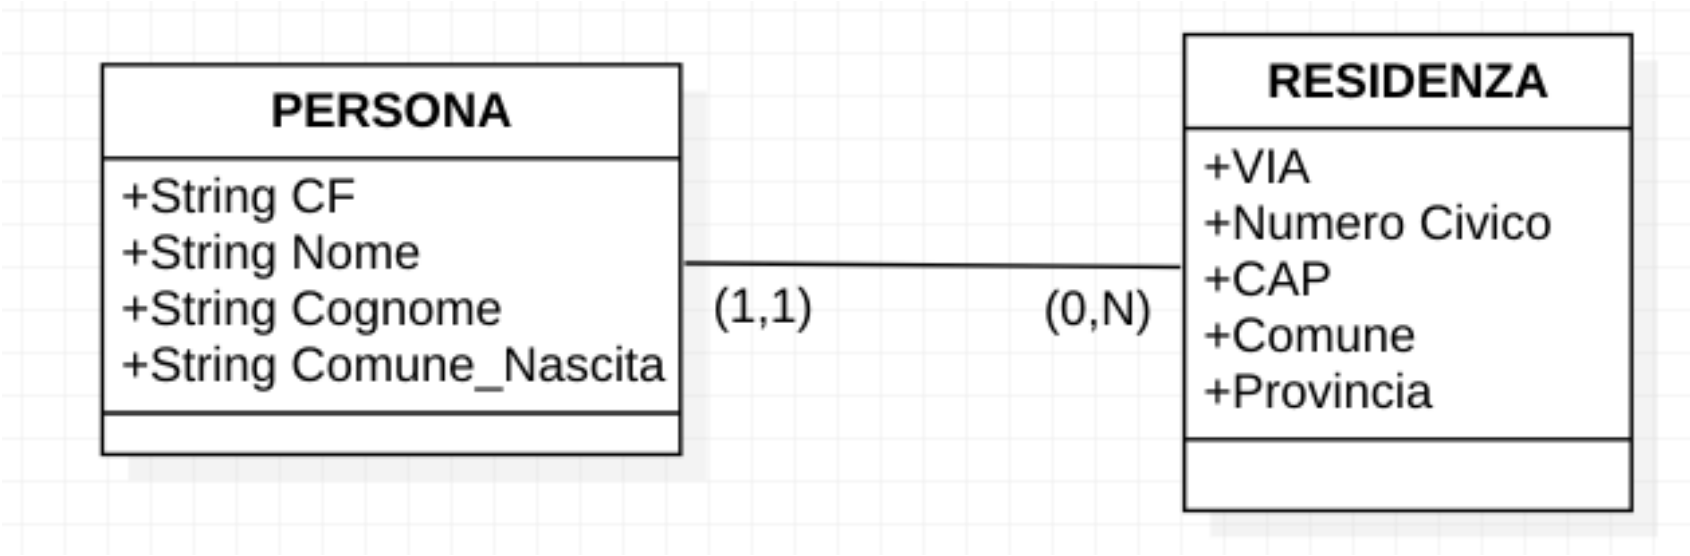


ELIMINAZIONE ATTRIBUTI STRUTTURATI

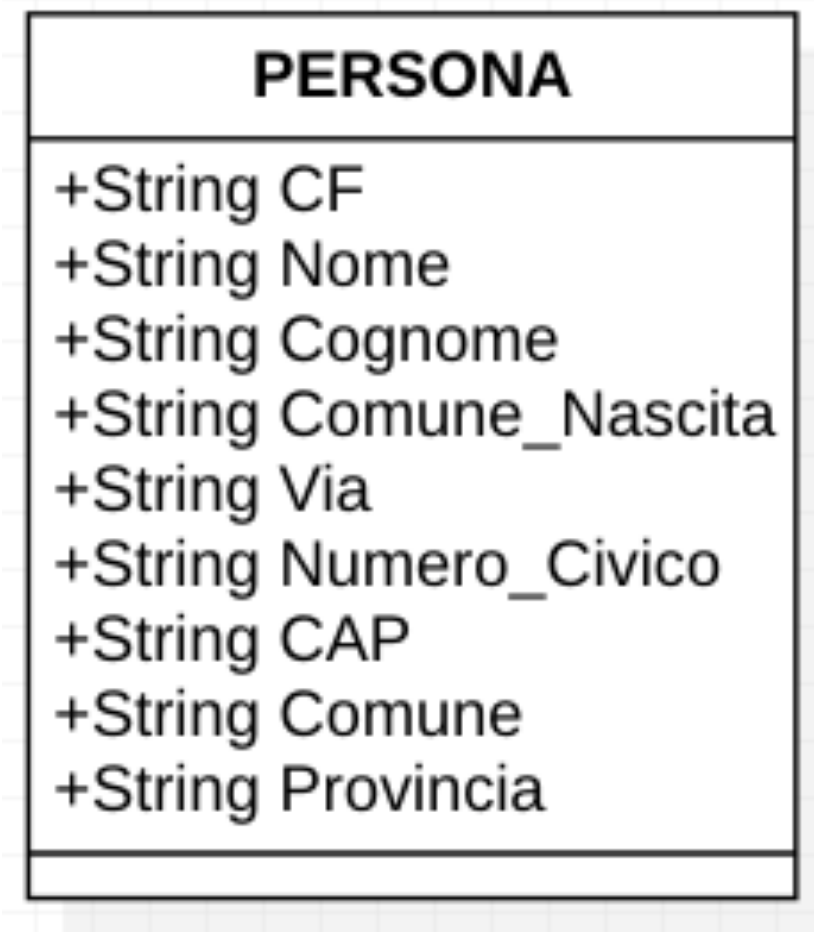




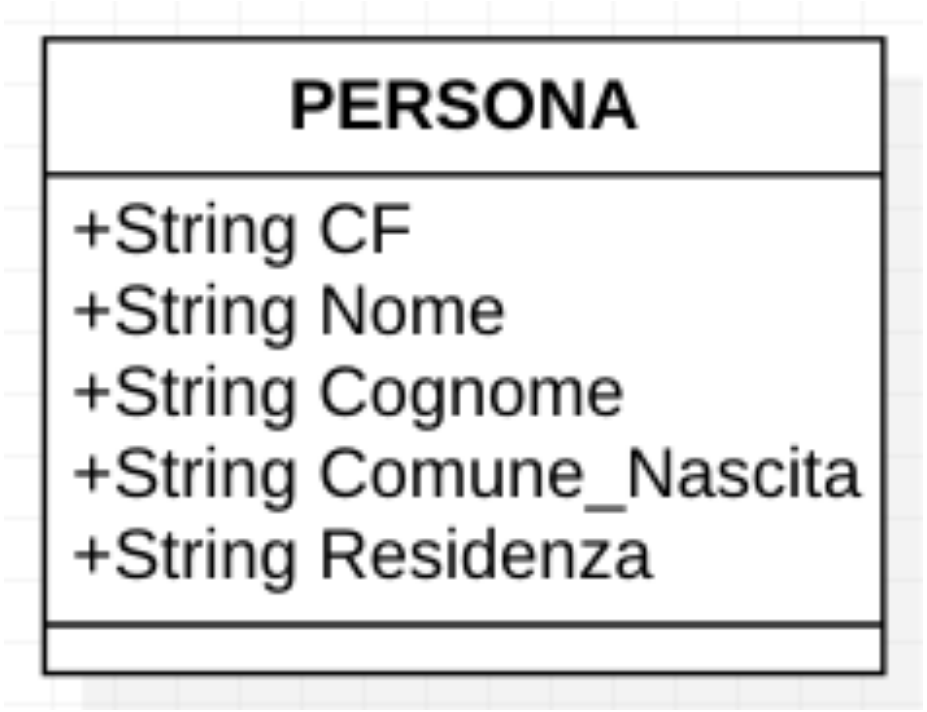
1) INTRODUZIONE DI UNA CLASSE PER L'ATTRIBUTO STRUTTURATO



2) ESTRAZIONE DEGLI ATTRIBUTI DELLA CLASSE



3) TRASCURARE LA STRUTTURA DELL'ATTRIBUTO



PARTIZIONAMENTO/ACCORPAMENTO DI ENTITÀ/ASSOCIAZIONI

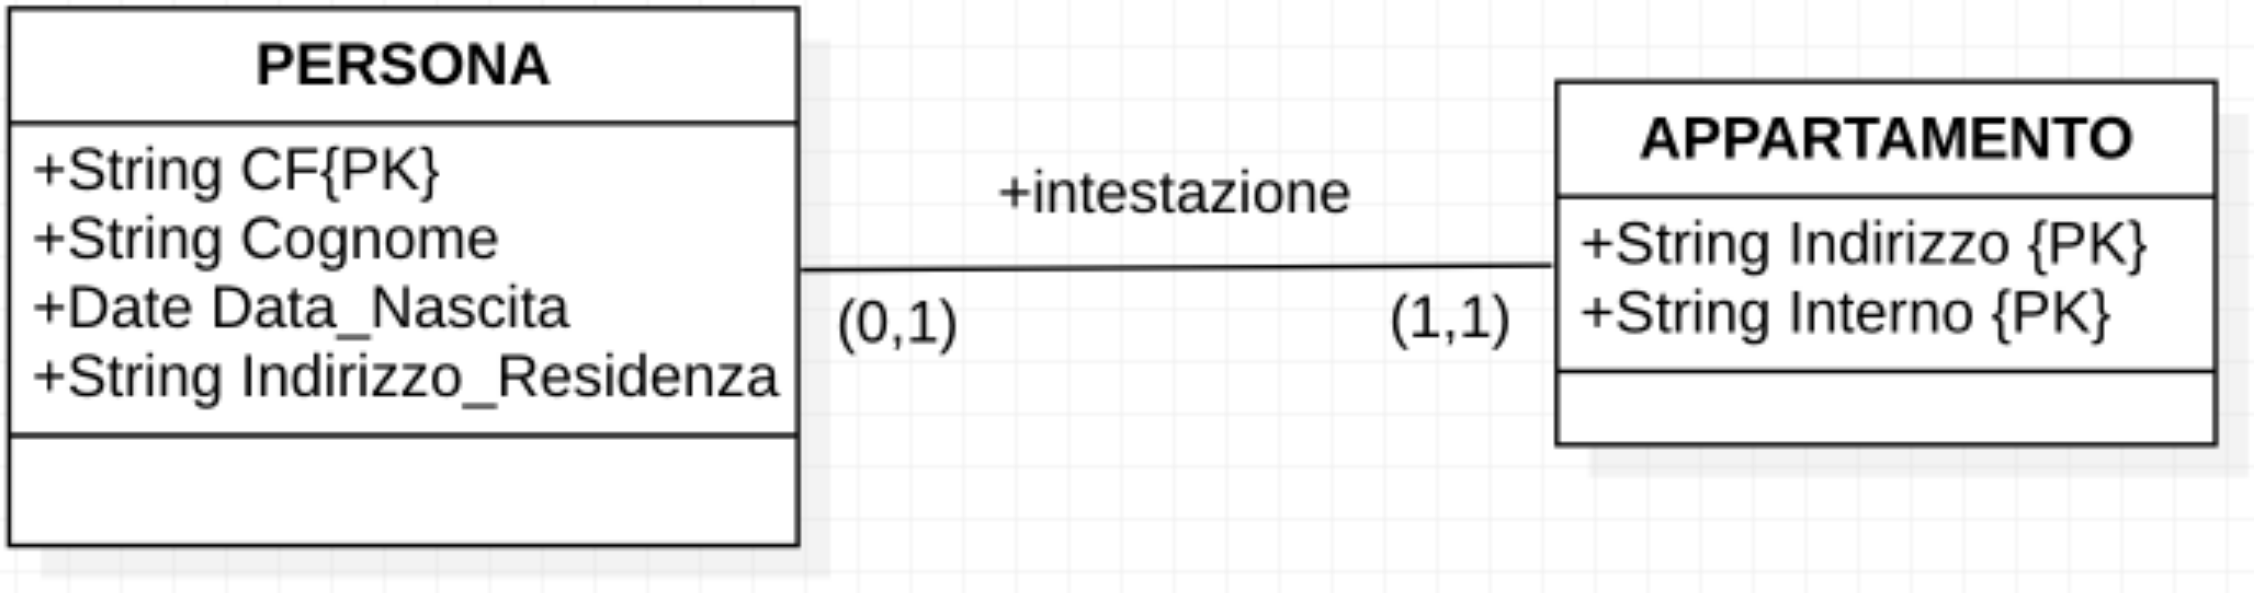


ACCORPAMENTI DI ENTITÀ

- Accorpamento dei concetti operando sulla struttura.
- È conveniente quando le operazioni accedono a dati presenti su entrambe le entità.
- Si effettua generalmente su associazioni di tipo 1:1.
- Presenza di valori nulli.

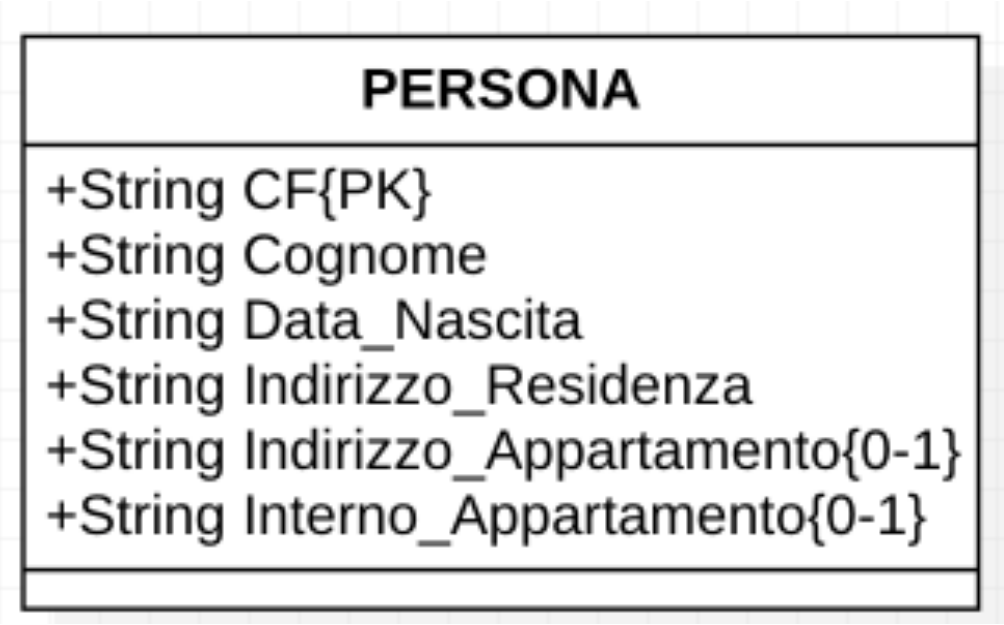


ACCORPAMENTI DI ENTITÀ - *ESEMPIO*

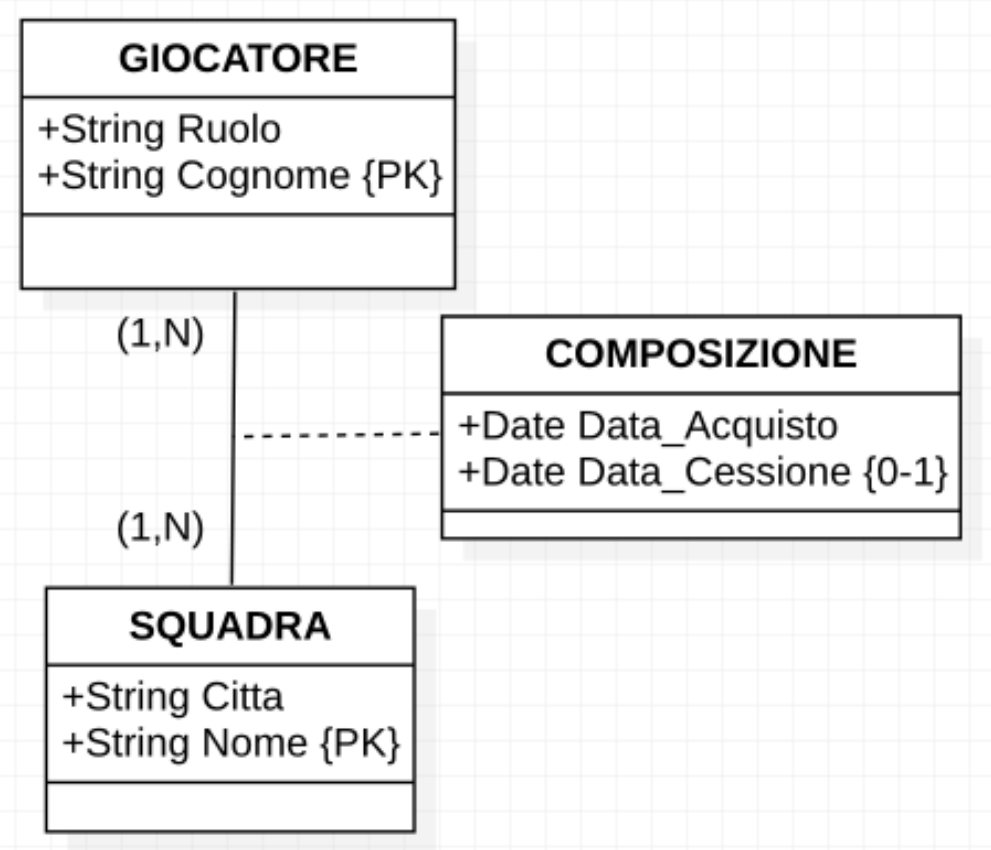


ACCORPAMENTI DI ENTITÀ – *ESEMPIO* (2)

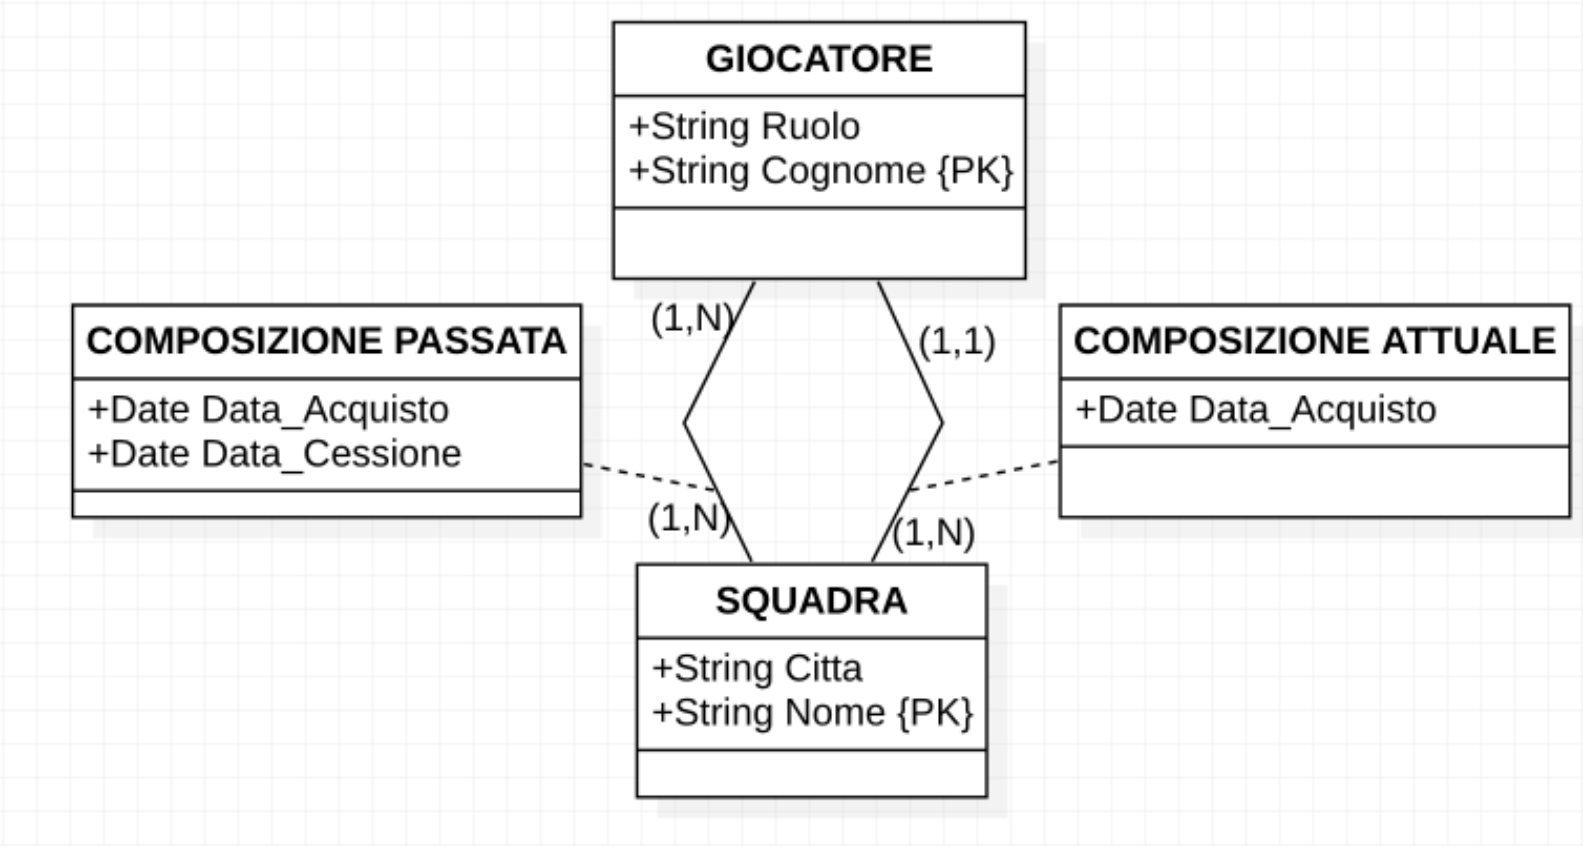
- Le operazioni più frequenti su persona richiedono sempre dati relativi all'appartamento che occupa:



DECOMPOSIZIONE DI ASSOCIAZIONI - *ESEMPIO*



DECOMPOSIZIONE DI ASSOCIAZIONI – *ESEMPIO* (2)



IDENTIFICATORE CHIAVI PRIMARIE



IDENTIFICATORI

- Scelta della chiave primaria per la costruzione degli indici per il recupero efficiente dei dati.
- Criteri generali:
  - Escludere attributi con valori nulli.
  - Numero minimo di attributi (dimensioni ridotte degli indici).
  - Identificatore coinvolto in molte operazioni.
  - Velocità di accesso all'indice.
    - Tempo minimo per confrontare i valori.
- Se nessuno degli identificatori candidati soddisfa tali criteri si introduce un ulteriore attributo all'entità:
  - Questo attibuto conterrà valori speciali (***codici***) generati appositamente per identificare le occorrenze delle entità.



IDENTIFICATORI: ESEMPIO

- Nel caso in cui l'entità Studente abbia **due** possibili chiavi:
  1. Matricola (10 caratteri, numerici).
  2. Codice fiscale (16 caratteri, alfanumerici).

- *Perché è opportuno selezionare l'attributo Matricola come identificatore primario?*
  - *La matricola richiede un tempo minore per confrontare due valori tra loro: la velocità di accesso all'indice è ridotta*

FINE

Per eventuali domande: (in ordine di preferenza personale)

- Ora.
- Chat di Teams
- Mail: silvio.barra@unina.it