

Lezione 11

AR (3° parte)

BASI DI DATI I

- Tutte le operazioni di Join (prima parte)
- Prima parte
- Seconda parte

Prof. Adriano Peron

Prof. Silvio Barra

A.A. 2021/2022

OPERAZIONI DI JOIN (1° PARTE)



JOIN

- La sequenza di operazioni appena vista, riassumibile in $\sigma_{join\text{-}condition}(R \times S)$ è abbastanza frequente: per questo è stata creata un'operazione speciale, chiamata JOIN.

- La JOIN, denotata con $\bowtie$, è usata per combinare tuple relate in una sola tupla.
  - $\sigma_{join\text{-}condition}(R \times S)$ diventa $R \bowtie_{join\text{-}condition} S$



JOIN: *ESEMPIO*

- Supponiamo di voler trovare il nome del manager di ciascun dipartimento:
  - Combiniamo ogni tupla dipartimento con la tupla impiegato il cui SSN fa match col valore MGRSSN nella tupla dipartimento.
- DEPT_MGR= department $\bowtie_{MGRSSN=SSN}$ EMPLOYEE
- RESULT= $\pi_{DNAME, LNAME, FNAME}$(DEPT_MGR)

DEPT_MGR	DNAME	DNUMBER	MGRSSN	• • •	FNAME	MINIT	LNAME	SSN	• • •
	Research	5	333445555	• • •	Franklin	T	Wong	333445555	• • •
	Administration	4	987654321	• • •	Jennifer	S	Wallace	987654321	• • •
	Headquarters	1	888665555	• • •	James	E	Borg	888665555	• • •



JOIN: *ESEMPIO SU PRODOTTO CARTESIANO*

- L'esempio precedente sul prodotto cartesiano può essere risolto rimpiazzando le operazioni:

  - EMP_DEPENDENTS = EMPNAMES x DEPENDENTS
  - ACTUAL_DEPENDENTS = $\sigma_{SSN=ESSN}$(EMP_DEPENDENTS)

  Con:

  - ACTUAL_DEPENDENTS = EMPNAMES $\bowtie_{SSN=ESSN}$ DEPENDENTS

OPERAZIONI DI JOIN (2° PARTE)



NOZIONI SULLA JOIN

- Sintassi :

  Date le relazioni $R(A_1, A_2, \ldots, A_n)$ e $S(B_1, B_2, \ldots, B_m)$

  Scriveremo $R \bowtie_{\text{<join_condition>}} S$

- Il risultato della join ha n+m attributi:

  $Q(A_1, A_2, \ldots, A_n, B_1, B_2, \ldots, B_m)$

- La condizione della join è della forma:
  <condition> AND <condition> AND … AND <condition>
  dove ogni condizione è della forma $A_i\ \theta\ B_j$,

  con $A_i \in R$, $B_j \in S$, $dom(A_i) = dom(B_j)$ e $\theta \in \{=,,\neq,<,>,\leq,\geq\}$

- Tuple con attributi di join **null** non appaiono nel risultato.



TIPI DI JOIN

- Una join con θ generica è detta THETA JOIN
- Il join più comune ha come θ l'operatore di uguaglianza ed è detto EQUIJOIN:
  - Nei risultati dell'EQUIJOIN abbiamo sempre una coppia di valori di attributi identici.

- Poiché tale ripetizione è superflua, esiste una nuova operazione, chiamata NATURAL JOIN e denotata da *, che elimina il secondo attributo superfluo.
  - È in sostanza una EQUIJOIN con la rimozione degli attributi con valori uguali superflui



Impiegati

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparti

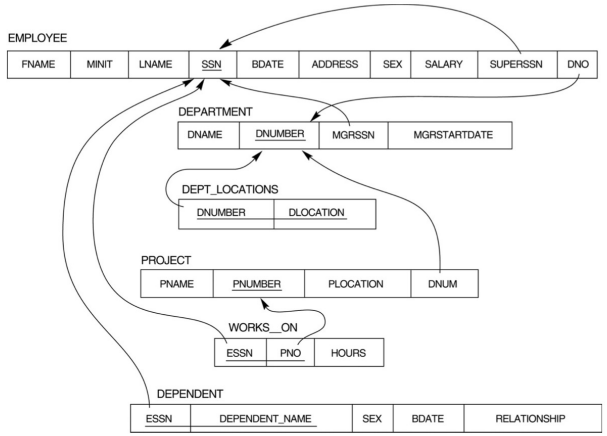
Codice	Capo
A	Mori
B	Bruni

Impiegati $\triangleright\!\triangleleft_{\text{Reparto=Codice}}$ Reparti

Impiegato	Reparto	Codice	Capo
Rossi	A	A	Mori
Neri	B	B	Bruni
Bianchi	B	B	Bruni



NATURAL JOIN

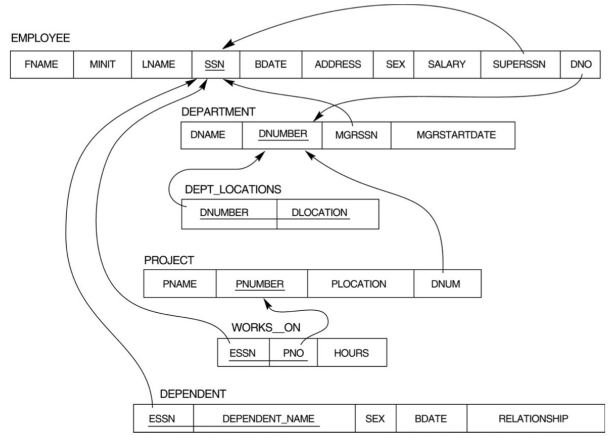


- La definizione standard di Natural join richiede che i due attributi di join (per ogni coppia) abbiano lo stesso nome. Se ciò non vale, occorre prima un'operazione di renaming.
  - DEPT= $\pi_{(\text{DNAME, DNUM, MGRSSN, MGRSTARTDATE})}$ (DEPARTMENT)
  - PROJ_DEPT = PROJECT * DEPT
    - L'attributo DNUM è detto "attributo di join"

PROJ_DEPT	PNAME	PNUMBER	PLOCATION	DNUM	DNAME	MGRSSN	MGRSTARTDATE
	ProductX	1	Bellaire	5	Research	333445555	1988-05-22
	ProductY	2	Sugarland	5	Research	333445555	1988-05-22
	ProductZ	3	Houston	5	Research	333445555	1988-05-22
	Computerization	10	Stafford	4	Administration	987654321	1995-01-01
	Reorganization	20	Houston	1	Headquarters	888665555	1981-06-19
	Newbenefits	30	Stafford	4	Administration	987654321	1995-01-01



NATURAL JOIN (2)



- Qualora gli attributi di join abbiano lo stesso nome, non e necessario il renaming.
- ***Esempio:***
  - DEPT_LOCS = DEPARTMENT * DEPT_LOCATIONS

DEPT_LOCS	DNAME	DNUMBER	MGRSSN	MGRSTARTDATE	LOCATION
	Headquarters	1	888665555	1981-06-19	Houston
	Administration	4	987654321	1995-01-01	Stafford
	Research	5	333445555	1988-05-22	Bellaire
	Research	5	333445555	1988-05-22	Sugarland
	Research	5	333445555	1988-05-22	Houston

- In generale il Natural Join verifica l'uguaglianza di tutte le coppie di attributi.

NATURAL JOIN (3)

Definizione più generale:

- Q = R*(<$list_1$>)(<$list_2$>)S
  - <$list_1$>=lista di attributi da R
  - <$list_2$>=lista di attributi da S

- Le liste sono usate per le uguaglianze tra coppie di attributi corrispondenti;
  - le condizioni sono combinate in AND.
  - Solo la lista corrispondente ad attributi della prima relazione, <$list_1$> è mantenuta nel risultato.



NATURAL JOIN (4)

- Se nessuna combinazione di tuple soddisfa la condizione di join, la relazione risultante avrà zero tuple:
  - Date le relazioni R(con $\mathbf{n_r}$ tuple) ed S (con $\mathbf{n_s}$ tuple),
    - $\mathbf{n_q}$ Q = R $\bowtie_{\text{<joincond>}}$ S avrà da **0** a $\mathbf{n_r} \cdot \mathbf{n_s}$ tuple.
    - $\mathbf{n_q}/(\mathbf{n_r} \cdot \mathbf{n_s})$ è detta join selectivity.

- Se non esiste alcuna <joincondition>, tutte le tuple compariranno nella relazione risultante, ed il join diventa un prodotto cartesiano, detto CROSS JOIN.



Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparto	Capo
A	Mori
B	Bruni

Impiegato	Reparto	Capo
Rossi	A	Mori
Neri	B	Bruni
Bianchi	B	Bruni

- Ogni *n*-pla contribuisce al risultato:
  - join completo.



UN JOIN NON COMPLETO

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparto	Capo
B	Mori
C	Bruni

Impiegato	Reparto	Capo
Neri	B	Mori
Bianchi	B	Mori



UN JOIN VUOTO

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparto	Capo
D	Mori
C	Bruni

Impiegato	Reparto	Capo



UN JOIN COMPLETO, CON N · M TUPLE

Impiegato	Reparto
Rossi	B
Neri	B

Reparto	Capo
B	Mori
B	Bruni

Impiegato	Reparto	Capo
Rossi	B	Mori
Rossi	B	Bruni
Neri	B	Mori
Neri	B	Bruni



CARDINALITÀ DEL JOIN

- Il join di R_1 e R_2 contiene un numero di *n*-ple compreso fra zero e il prodotto di $|R_1|$ e $|R_2|$.

- Se il join coinvolge una chiave di R_2, allora il numero di *n*-ple è compreso fra zero e $|R_1|$.

- Se il join coinvolge una chiave di R_2 e un vincolo di integrità referenziale, allora il numero di *n*-ple è pari a $|R_1|$.



(animazione)

JOIN, UNA DIFFICOLTÀ

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparto	Capo
B	Mori
C	Bruni

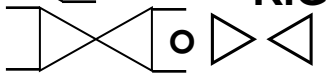
Impiegato	Reparto	Capo
Neri	B	Mori
Bianchi	B	Mori

- Alcune *n*-ple non contribuiscono al risultato: vengono *"tagliate fuori"*.



JOIN ESTERNO

- Il join esterno estende, con valori nulli, le *n*-ple che verrebbero tagliate fuori da un join (interno).

- Esiste in tre versioni:
  - sinistro ( **LEFT**),
  - destro ( **RIGHT**),
  - completo ( **FULL**).

JOIN ESTERNO (2)

- Sinistro: mantiene tutte le *n*-ple *del primo operando*, estendendole con valori nulli, se necessario.

- Destro: … *del secondo operando* …

- Completo: … *di entrambi gli operandi* …



Impiegati

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparti

Reparto	Capo
B	Mori
C	Bruni

Impiegati $\triangleright\!\triangleleft_{\text{LEFT}}$ Reparti

Impiegato	Reparto	Capo
Neri	B	Mori
Bianchi	B	Mori
Rossi	A	NULL



Impiegati

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparti

Reparto	Capo
B	Mori
C	Bruni

Impiegati $\triangleright\!\triangleleft_{\text{RIGHT}}$ Reparti

Impiegato	Reparto	Capo
Neri	B	Mori
Bianchi	B	Mori
NULL	C	Bruni



Impiegati

Impiegato	Reparto
Rossi	A
Neri	B
Bianchi	B

Reparti

Reparto	Capo
B	Mori
C	Bruni

Impiegati $\triangleright\triangleleft_{\text{FULL}}$ Reparti

Impiegato	Reparto	Capo
Neri	B	Mori
Bianchi	B	Mori
Rossi	A	NULL
NULL	C	Bruni



L'OPERAZIONE DI DIVISIONE



L'OPERAZIONE DI DIVISIONE

- L'operazione di divisione è indicata con ÷ è un tipo particolare di interrogazione che talvolta si presenta nelle applicazioni di basi di dati.
- Un esempio è *"trova i nomi degli impiegati che lavorano a **tutti** i progetti su cui lavora 'John Smith'"*.

- La divisione ÷, di r1 per r2, con r1 su $R_1(X_1X_2)$ e r2 su $R_2(X_2)$, è (il più grande) insieme di tuple con schema X_1 tale che, facendo il prodotto cartesiano con r2, ciò che si ottiene è una relazione contenuta in r1.

ESEMPIO

Voli

Codice	Data
AZ427	21/07/2001
AZ427	23/07/2001
AZ427	24/07/2001
TW056	21/07/2001
TW056	24/07/2001
TW056	25/07/2001

Linee

Codice
AZ427
TW056

Voli ÷ Linee

Data
21/07/2001
24/07/2001

(Voli ÷ Linee) ⋈ Linee

Codice	Data
AZ427	21/07/2001
AZ427	24/07/2001
TW056	21/07/2001
TW056	24/07/2001

La divisione trova le date con voli per tutte le linee



UN INSIEME COMPLETO DI OPERAZIONI

- Si può provare che $\{\sigma, \pi, \cup, -, \times\}$ è un insieme completo, cioè tutte le altre operazioni possono essere espresse come combinazioni di queste.
- ***Esempi:***
  - Intersezione:
    - $R \cap S = (R \cup S) - ((R - S) \cup (S - R))$
  - Join:
    - $R \bowtie_{<condition>} S = \sigma_{<condition>}(R \times S)$
  - Divisione:
    - $R \div S = T1 \leftarrow \pi_{<attribute\ of\ R\ -\ attribute\ of\ S>}(R)$

      $T2 \leftarrow \pi_{<attribute\ of\ R\ -\ attribute\ of\ S>}((S \times T1) - R)$

      $T \leftarrow T1 - T2$

ALGEBRA RELAZIONALE: LIMITI

- Ci sono però interrogazioni interessanti non esprimibili:
  - Calcolo di valori derivati: possiamo solo estrarre valori, non calcolarne di nuovi; calcoli di interesse:
    - a livello di *n*-pla o di singolo valore (conversioni somme, differenze, etc.);
    - su insiemi di *n*-ple (somme, medie, etc.).
  - Interrogazioni inerentemente ricorsive, come la chiusura transitiva.



FUNZIONI AGGREGATE E DI RAGGRUPPAMENTO

- *Non sono presenti nell'algebra relazionale base.*
- Operano su un insieme di dati per restituire come risultato una relazione con un solo valore.
- Sono funzioni applicate a collezioni di valori numerici:
  - SUM, AVERAGE, MAXIMUM, MINIMUM, COUNT.
- *Notazione:*

  <attributi di raggruppamento>$\mathscr{F}$<lista funzioni>(R)
  - dove <attributi di raggruppamento> è una lista di attributi della relazione R e raggruppa le tuple presenti nella relazione sulla base dei loro valori,
  - e <lista funzioni> è una lista di coppie <funzione><attributo>:
    - <funzione> è una delle funzioni SUM,…
    - <attributo> è un attributo della relazione R.



ESEMPIO

- $T(N_D, N_IMP, STIP_MEDIO) \leftarrow {}_{N_D}\mathcal{F}_{COUNT\ SSN,\ AVERAGE\ STIPENDIO}(IMPIEGATO)$
- $R \leftarrow \sigma_{N_D,\ N_IMP,STIP_MEDIO}(T)$

R	N_D	N_IMP	STIP_MEDIO
	5	4	33250
	4	3	31000
	1	1	55000

- $S \leftarrow \mathcal{F}_{CO}$

S	COUNT_SSN	AVERAGE_STIPENDIO
	8	35125



EQUIVALENZA DI ESPRESSIONI

- Due espressioni sono equivalenti se producono lo stesso risultato qualunque sia l'istanza attuale della base di dati.

- L'equivalenza è importante perché i DBMS cercano di eseguire espressioni equivalenti a quelle date, ma meno *"costose"*.

- Trasformazioni di equivalenza.



FINE

Per eventuali domande: (in ordine di preferenza personale)

- Ora.
- Chat di Teams
- Mail: silvio.barra@unina.it